
Testen van hypothesen

Nagaan van de plausibiliteit van uitspraken
over populatie-grootheden

P.L. Ottoy

IR18

1

K&Z § 6.3.1 ; W hoofdstuk 9.

Statistisch testen van een hypothese

- ⇒ hypothese = uitspraak over populatie-grootheid (parameter van een distributie)
- ⇒ onderzoek naar de plausibiliteit
 - gebeurt op basis van een RS (RSWR of RSWOR) en een daaruit berekende statistiek
 - verloopt volgens een geijkte procedure = recept, bekend als “het testen (toetsen) van hypothesen”

Hoe werkt de testprocedure ? 1


⇒ voorbeeld : productieprocédé voor beeldbuizen

- twee tegenovergestelde standpunten
- de populatiegrootte waar het om gaat is μ
- de statistiek is het steekproefgemiddelde (σ bekend)

⇒ formaliseren van de standpunten

- $H_0 : \mu = 1200$ - de nulhypothese
- $H_A : \mu > 1200$ - de alternatieve hypothese

⇒ vertaling naar de distributie van de statistiek



IR18


3

Een nieuwe productiemethode voor beeldbuizen dient te worden geëvalueerd. De nieuwe methode levert volgens de voorstanders beeldbuizen met een langere levensduur op. Volgens de tegenstanders is dit niet het geval. De distributie van de levensduren zal moeten uitsluitsel bieden.

We nemen aan dat onder het beproefde productieprocédé beeldbuizen een levensduur hebben die normaal verdeeld is met een gemiddelde van 1200 tijdseenheden en een spreiding van 300. Er wordt een onderzoek opgezet op basis van een steekproef van 100 beeldbuizen vervaardigd volgens het nieuwe procédé.

Hoe werkt de testprocedure ? 2

- ⇒ uit het RS hebben we één waarde van de statistiek
- ⇒ we vergelijken deze waarde met de distributie van de statistiek “onder H_0 ” : de referentiedistributie



Hoe werkt de testprocedure ? 3

⇒ fouten gekoppeld aan de testprocedure


		de realiteit	
		H_0 geldt	H_A geldt
ons besluit	H_0 geldt	OK	type-II fout risico = β
	H_A geldt	type-I fout risico = α	OK

Hoe werkt de testprocedure ? 4

- ⇒ betekenis type-I fout : investeren in een procédé dat niet beter is $\Rightarrow$ risico α op begaan van deze fout moet alleszins aanvaardbaar klein zijn
 - ⇒ α hangt af van economische context en wordt a priori bepaald
 - ⇒ α is oppervlakte onder referentiedistributie rechts van kritische waarde $\Rightarrow$ kritische waarde moet “in de rechter staart” van de distributie liggen
 - ⇒ α wordt de significantie van de test genoemd
 - ⇒ we aanvaarden of verwerpen H_0 bij significantie α ;
we testen de hypothesen bij significantie α
-

Hoe werkt de testprocedure ? 5


- ⇒ waarom niet gewoon $\alpha = 0$? (leg kritische waarde ver genoeg)
- ⇒ hier speelt de type-II fout mee : betekenis = missen van mogelijk interessante investering



- ⇒ er is een trade-off tussen α en β : $\alpha \downarrow \Leftrightarrow \beta \uparrow$
- ⇒ door α onredelijk laag te kiezen wordt β onaanvaardbaar hoog

Hoe werkt de testprocedure ? 6

- ⇒ β is ook afhankelijk van de “afstand tussen de nulhypothese en de realiteit” (voor gegeven α)
- ⇒ het verloop van in functie van die afstand wordt de OC-curve genoemd (Operating Characteristic Curve)



IR18

8

De Operating Characteristic is een negatieve maat, vermits ze het risico weergeeft op het begaan van de type-II fout. Een equivalente, maar positieve maat is de **kracht** of de **sensitiviteit** van de test. Notatie ψ . De kracht geeft de kans weer op het terecht verwerpen van de nulhypothese, d.w.z. $\psi(\lambda) = 1 - OC(\lambda)$.

Wanneer er verschillende tests voorhanden zijn, komt het erop aan deze te kiezen met de hoogste kracht of sensitiviteit. Immers voor elke test is de significantie α dezelfde. Tests onderscheiden zich dus enkel o.b.v. β .


De kracht is bepalend voor de efficiëntie van de test. Stel gegeven twee tests T_1 en T_2 , waarbij T_1 krachtiger is, d.w.z. $\psi_1(\lambda) > \psi_2(\lambda)$ wanneer beide tests op dezelfde steekproeflengte n gebaseerd zijn. We kunnen nu de steekproeflengte voor T_1 laten afnemen tot op het punt m zodat $\psi_1(\lambda) = \psi_2(\lambda)$. De verhouding n/m is de relatieve efficiëntie van T_1 t.o.v. T_2 .

W § 9.5.

Als oefening : bereken m.b.v. R de OC-curve en de krachtcurve voor de Z-test. Voeg meerdere OC-curven voor verschillende steekproeflengtes samen in één figuur.

Hoe werkt de testprocedure ? 7

- ⇒ idealiter zijn α en β beide klein
- ⇒ dit kan maar heeft een prijs : grotere steekproef
- ⇒ dit is de derde afhankelijkheid van β : de steekproefgrootte



Recept eenzijdige test


- | | |
|---|---|
| <p>① formuleer H_0 en H_A</p> <p>② kies significantie α</p> <p>③ kies de statistiek (uiteraard verwant aan te testen populatiegrootheid)</p> <p>④ kies lengte steekproef</p> <p>⑤ bepaal kritische waarde door afpassen α op distributie statistiek onder H_0 (juiste kant !)</p> <p>⑥ bereken waarde statistiek voor steekproef</p> <p>⑦ vergelijk waarde met kritische waarde en besluit</p> | <p>① $H_0 : \mu = \mu_0 = 1200$; $H_A : \mu > \mu_0$</p> <p>② $\alpha = 1 \%$</p> <p>③ $\bar{X}$ ($\sigma = 300$ gekend)</p> <p>④ $n = 100$</p> <p>⑤ kritische waarde in <u>rechter</u> staart = $1200 + 2.3 \cdot 30 = 1270$</p> <p>⑥ berekende waarde statistiek = 1265</p> <p>⑦ $1265 < 1270 \Rightarrow$ aanvaard H_0</p> |
|---|---|

IR18

10

Beslissen op basis van de p-waarde

- ⇒ klassiek : bepalen kritische waarde uit significantie en vervolgens vergelijken waarde statistiek met kritische waarde
- ⇒ beter : rechtstreekse vergelijking p-waarde met significantie
- ⇒ p-waarde = indicatie van de mate waarin de waarde van de statistiek H_0 ondersteunt (kleine p-waarde : H_0 niet plausibel, grote p-waarde : H_0 wel plausibel)
- ⇒ voordeel : onafhankelijke beoordeling



IR18

11

W oefening 9-8 ; W § 9.2.

An anecdote by Crichton (“A case of need”, 1968) goes like this : There’s this desert prison, see, with an old prisoner, resigned to his life, and a young one just arrived. The young one talks constantly of escape, and, after a few months, he makes a break. He’s gone a week, and then he’s brought back by the guards. He’s half dead, crazy with hunger and thirst. He describes how awful it was to the old prisoner. The endless stretches of sand, no oasis, no signs of life anywhere. The old prisoner listens for a while, then says, “Yep, I know, I tried to escape myself, twenty years ago.” The young prisoner says, “You did ? Why didn’t you let me know it was impossible ?” And the old prisoner shrugs, and says, “So who publishes negative results ?”

This simple story reflects a serious concern by social scientists about classical 5 % testing (Light and Pillemer, 1984). To elaborate, suppose a revolutionary hypothesis has been proposed by the famous professor Brainstorm, and yet if the truth were known, it really wouldn’t fit the facts. In formal language, it is the null hypothesis that is true, not Brainstorm’s hypothesis.

- a. If 100 researchers investigated this phenomenon, about how many would obtain “statistically significant” results so they could claim the Brainstorm hypothesis was true after all (at the 5 % level) ?
- b. Now suppose the *Journal of Statistically Significant Results* used “statistical significance at the 5 % level” as its sole criterium for publishing. (An exaggeration, of course, but we will use it to illustrate some real problems.) If all 100 researchers submitted their papers to this journal, which ones would get published ?


For anyone who looks at the published evidence, what would he conclude about the Brainstorm hypothesis ?

Eenzijdige test vs. dubbelzijdige test

- ⇒ eenzijdige test geschikt om verschil in één richting te ontdekken
- ⇒ verschillen in beide richtingen ontdekken : dubbelzijdige test
- ⇒ de wijzigingen t.o.v.

eenzijdige test zijn :

- formulering $H_A : \mu \neq \mu_0$
- twee kritische waarden : verdeling significantie over beide staarten
- waarde statistiek tussen kritische waarden $\Rightarrow$ aanvaard H_0 , zoniet aanvaard H_A : d.w.z. $\mu < \mu_0$ of $\mu > \mu_0$



Recept dubbelzijdige test


- | | |
|---|--|
| <ul style="list-style-type: none"> ① formuleer H_0 en H_A ② kies significantie α ③ kies de statistiek (uiteraard verwant aan te testen populatiegrootte) ④ kies lengte steekproef ⑤ bepaal kritische waarden door afpassen $\alpha/2$ op distributie statistiek onder H_0 (beide staarten) ⑥ bereken waarde statistiek voor steekproef ⑦ vergelijk waarde met kritische waarden en besluit | <ul style="list-style-type: none"> ① $H_0 : \mu = \mu_0 = 1200$; $H_A : \mu \neq \mu_0$ ② $\alpha = 1 \%$ ③ $\bar{X}$ ($\sigma = 300$ gekend) ④ $n = 100$ ⑤ kritische waarden :
links $1200 - 2.6 \cdot 30 = 1123$
rechts $1200 + 2.6 \cdot 30 = 1277$ ⑥ berekende waarde statistiek = 1265 ⑦ $1123 < 1265 < 1277 \Rightarrow H_0 \text{ OK}$ |
|---|--|

IR18

13

Waarom ooit een eenzijdige test ?

- ⇒ met dubbelzijdige test kunnen we verschillen in twee richtingen ontdekken
- ⇒ eenzijdige test presteert wel beter in de gekozen richting : groter onderscheidingsvermogen of kracht
- ⇒ blijkt uit vergelijking OC-curven (zelfde α en n)



IR18


14

Een eenzijdige test is dus krachtiger dan een tweezijdige gebaseerd op dezelfde steekproef. Als prijs hiervoor betaalt de eenzijdige test het niets kunnen detecteren in één van beide richtingen.

Als oefening bereken in R de relatieve efficiëntiecurve $\text{eff}(\lambda)$ van de eenzijdige Z-test t.o.v. de tweezijdige Z-test. Wat gebeurt er met de curve als de steekproeflengte n toeneemt ?

Dubbelzijdige p-waarde

- ⇒ ook bij dubbelzijdige test is beslissing op basis van p-waarde mogelijk
- ⇒ definitie van begrip p-waarde moet worden verruimd ⇒ dubbelzijdige p-waarde



De link naar betrouwbaarheidsintervallen 1

⇒ legitimatie werkwijze vb. schoenzooldata

- gn syst. verschil als $0 \in \text{BI}$ voor $\mu_1 - \mu_2 \Leftrightarrow \text{aanv. } H_0 : \mu_1 - \mu_2 = 0$
- syst. verschil als $0 \notin \text{BI}$ voor $\mu_1 - \mu_2 \Leftrightarrow \text{aanv. } H_A : \mu_1 - \mu_2 \neq 0$

⇒ $H_0 : \mu = \mu_0$ vs. $H_A : \mu \neq \mu_0$ testen bij $\alpha = 5\%$ - σ gekend

- RS lengte n , statistiek $= \bar{X}$

- distributie $\bar{X}$ onder $H_0 : \bar{X} \sim N(\mu_0, \frac{\sigma}{\sqrt{n}})$

- anv. $H_0 : \mu = \mu_0$ bij 5% sign. $\Leftrightarrow \mu_0 - Z_{0.025} \frac{\sigma}{\sqrt{n}} \leq \bar{x} \leq \mu_0 + Z_{0.025} \frac{\sigma}{\sqrt{n}}$

$$\Leftrightarrow \bar{x} - Z_{0.025} \frac{\sigma}{\sqrt{n}} \leq \mu_0 \leq \bar{x} + Z_{0.025} \frac{\sigma}{\sqrt{n}}$$

$$\Leftrightarrow \mu_0 \text{ ligt in het } 95\% - \text{BI rond } \bar{x}$$

De link naar betrouwbaarheidsintervallen 2

- ⇒ conclusie : het 95%-BI is de set van nulhypotheseën die we bij 5% significantie aanvaarden
- ⇒ algemeen :
significantie test + betrouwbaarheid interval = 100 %
- ⇒ omdat verondersteld σ bekend, kunnen BI en kritische waarden uit test worden bepaald uit Z-distributie : we spreken van de Z-test voor μ
- ⇒ Z-test is niet courant voor μ , komt wel te pas in andere situaties

De link naar betrouwbaarheidsintervallen 3

⇒ naar analogie van link tussen dubbelzijdige test en (dubbelzijdig) BI kunnen we eenzijdig BI associëren met eenzijdige test

⇒ $H_0 : \mu = \mu_0$ vs. $H_A : \mu > \mu_0$ testen bij $\alpha = 5\%$ - σ gekend
aanv. $H_0 : \mu = \mu_0$ bij 5% sign. $\Leftrightarrow \mu_0$ ligt in het 95% - BI (analogie)

$$\Leftrightarrow \bar{x} \leq \text{krit.w.} = \mu_0 + Z_{0.05} \frac{\sigma}{\sqrt{n}} \text{ (testconditie)}$$

$$\Leftrightarrow \mu_0 \geq \bar{x} - Z_{0.05} \frac{\sigma}{\sqrt{n}} \text{ (algebra)}$$

⇒ aaneenschakeling equivalenties :

$$\text{eenzijdig 95\% - BI voor } \mu = \left[\bar{x} - Z_{0.025} \frac{\sigma}{\sqrt{n}}, +\infty \right[$$

De link naar betrouwbaarheidsintervallen 4

$$H_0 : \theta = \theta_0$$

$$H_A : \theta \neq \theta_0$$

aanvaardingsgebied voor H_0 :


$$[\underline{K}_\alpha(\theta_0), \bar{K}_\alpha(\theta_0)]$$

gegeven een waarde T voor de test-statistiek, noteer :

$$L_\alpha(T) = \inf\{\theta : T \leq \bar{K}_\alpha(\theta)\}$$

$$U_\alpha(T) = \sup\{\theta : T \geq \underline{K}_\alpha(\theta)\}$$

dan is $[L_\alpha(T), U_\alpha(T)]$ een $(1 - \alpha) \times 100$ % BI voor θ



IR18

19

Redelijkerwijze zijn de functies $\bar{K}_\alpha(\theta)$ en $\underline{K}_\alpha(\theta)$ stijgende functies van θ . Het interval $[L_\alpha(T), U_\alpha(T)]$ is de set van alle nulhypotheseën die we op grond van de waarde T aanvaarden.

Zij nu θ^* de ware waarde van θ . Dan geldt : $P(H_0 : \theta = \theta^* \text{ wordt aanvaard}) = (1 - \alpha)$. Maar H_0 wordt net aanvaard wanneer θ^* ligt in het interval $[L_\alpha(T), U_\alpha(T)]$. Derhalve geldt $P(\theta^* \in [L_\alpha(T), U_\alpha(T)]) = 1 - \alpha$. Het interval is dus wel degelijk een $(1 - \alpha) \times 100$ % betrouwbaarheidsinterval voor θ .

K&Z § 6.4

De link naar betrouwbaarheidsintervallen 5

toegepast op het BI voor π ; exacte berekening op basis van de binomiaalverdeling


$$\underline{K}_\alpha(\pi) = \frac{1}{n} B^{-1}(\alpha/2; n; \pi)$$

$$\overline{K}_\alpha(\pi) = \frac{1}{n} B^{-1}(1 - \alpha/2; n; \pi)$$

$$L_\alpha(p) = \inf\{\pi : p \leq \overline{K}_\alpha(\pi)\}$$

$$U_\alpha(p) = \sup\{\pi : p \geq \underline{K}_\alpha(\pi)\}$$

$$p = 0.6 \Rightarrow \text{BI} = [0.53, 0.67]$$



IR18

20

K&Z § 6.4.4

In het vorige hoofdstuk, leidden we een benaderd 95 % BI voor π af uitgaande van de normale verdeling. Het hier bepaalde BI is exact berekend uitgaande van de binomiaalverdeling.

De curven $\overline{K}_\alpha(\theta)$ en $\underline{K}_\alpha(\theta)$ zijn opgenomen in nomogrammen voor verschillende waarden van de steekproeflengte n . Aldus kan, met voor de praktijk afdoende nauwkeurigheid, het betrouwbaarheidsinterval in een oogwenk grafisch worden bepaald. Op de horizontale as is de populatie-proportie π weergegeven. Op de verticale as de steekproefproportie p . In de getoonde figuur is de steekproeflengte $n = 200$.

Bij wijze van oefening, reconstrueer de figuur aan de hand van R. In R wordt het 95 % BI voor π bepaald via de functie `binom.test : binom.test(120, 200)` levert als BI op : `[0.53, 0.67]`.

Nog als oefening, pas dit principe toe voor de bepaling van een BI voor μ , aangenomen dat σ bekend is. Verifieer de gevolgde redenering aan de hand van K&Z § 6.4.1.

Valkuilen

- ⇒ interpretatie van het aanvaarden van $H_0 : \mu = \mu_0$
- ⇒ arbitraire keuze van α leidt tot arbitraire beslissingen
- ⇒ een significant verschil is niet noodzakelijk relevant
- ⇒ naast de data kan er andere waardevolle informatie zijn

Oefening

- ⇒ Een productieproces heeft een defectrate π . De kwaliteitsdienst test $H_0 : \pi = 0.02$ vs. $H_A : \pi > 0.02$ en neemt daartoe een steekproef van lengte 400. Het aantal gevonden defectieven is 10. Tot welke conclusie komt de kwaliteitsdienst op basis van dit onderzoek ? (Maak een schets van de distributie van de gebruikte statistiek, met aanduiding van aanvaardingsgebied voor H_0 . Bereken tevens de p-waarde.)
- ⇒ Wat is de kans dat de kwaliteitsdienst H_0 nog aanvaardt wanneer de werkelijke defectrate 3 % bedraagt ?
- ⇒ Hoe groot moet de kwaliteitsdienst zijn steekproef nemen opdat de kans dat H_0 wordt aanvaard bij een werkelijke defectrate van 3 % kleiner zou zijn dan 10 % ?